PÓS-TECH • DEVOPS • FIAP

TECH CHALLENGE

FASE 2

ToggleMaster

Implementação de Arquitetura de Microsserviços na AWS

Afonso Victoriano Franco • Cesar Augusto Ferreira Alves
Jeferson Lima Papalino • Jonatas Ariel Nunes • Willian Felix Corrêa

Outubro de 2026 | AWS Academy — us-east-1

Identificação e dados da entrega

Integrante	RM	Discord
Afonso Victoriano Franco	RM373563	afonso3254
Cesar Augusto Ferreira Alves	RM376614	cesarf__
Jeferson Lima Papalino	RM376680	jefersonpapalino
Jonatas Ariel Nunes	RM376145	eusoujoe
Willian Felix Corrêa	RM372688	will1an2522

Identificação completa: RM e Discord dos cinco integrantes. O repositório e o vídeo de demonstração (YouTube, 18:19) estão na seção 23.

Visão rápida do resultado

EKS	NÓS	APLICAÇÕES
Kubernetes 1.37	**2 em estado Ready**	**5 Deployments 1/1**
SEGREDOS	**ENTRADA**	**FLUXO E2E**
4 ExternalSecrets	**Classic LB + Ingress (4 rotas)**	**LB → SQS → DynamoDB validado**

Estado comprovado no LAB 2, em 30/10 e 02/11/2026 (evidências 02 a 14); recursos de laboratório são transitórios.

Sumário

1. Introdução 5
2. Objetivo 6
3. Evolução da arquitetura 7
3.1 Microsserviços 7
3.2 Fluxo funcional 7
4. Atendimento aos requisitos da Fase 2 9
5. Ambiente local com Docker Compose 10
5.1 Containers locais 10
5.2 Execução local 11
5.3 Kubernetes local 11
6. Conteinerização 12
7. Arquitetura AWS implantada 13
7.1 Inventário principal 13
7.2 Provisionamento do Amazon EKS 13
7.3 Imagens publicadas 14
7.4 Endpoint externo 14
8. Kubernetes no EKS 15
8.1 Recursos e probes 15
8.2 Roteamento do Ingress 15
8.3 Inicialização dos bancos 16
9. Serviços de dados e mensageria 17
9.1 RDS PostgreSQL 17
9.2 ElastiCache Redis 17
9.3 SQS e DynamoDB 17
9.3.1 Esquema da tabela analítica 17
10. Segurança 18
10.1 Gestão de segredos 18
10.2 Segurança dos containers 18
10.3 Rede e identidade 18
11. Escalabilidade e resiliência 19
12. Configuração e sequência de implantação 20
13. Correção do evaluation-service 21
14. Validação da aplicação 22
14.1 Teste seguro pelo endpoint público 22
15. Evidências reais e rastreabilidade 23
15.1 Docker Compose — coleta atual 23
15.2 Kubernetes local — baseline dos HPAs 24

15.3 Inventário AWS comprovado no LAB 2 24
15.4 Demonstração dos HPAs no EKS 24
16. Arquitetura de microsserviços 25
16.1 Vantagens 25
16.2 Desvantagens e novos custos operacionais 25
17. Análise dos 12-Factor App 26
18. Considerações de custos 27
19. Desafios encontrados 28
20. Decisões técnicas 29
21. Limitações e melhorias recomendadas 30
22. Conclusão 31
23. Links e arquivos da entrega 32
Checklist antes do envio 32
Validação final do AWS Lab 33
Identidade de execução do EKS 33
Fluxo funcional observado 33
Decisões e limitações 33

O sumário cacheado já contém todas as seções. Ao abrir no Word, use Ctrl+A e F9 para recalcular a paginação final.

1. Introdução

Na Fase 1, o ToggleMaster foi disponibilizado como uma aplicação monolítica executada em instâncias Amazon EC2 e conectada a um banco PostgreSQL no Amazon RDS. A solução foi adequada para validar o MVP, mas a evolução do volume de acessos e da complexidade funcional passou a exigir componentes independentes, escaláveis e com responsabilidades bem definidas.

Na Fase 2, o sistema foi decomposto em cinco microsserviços: autenticação, gerenciamento de feature flags, regras de segmentação, avaliação de flags e processamento analítico. Cada serviço foi conteinerizado, recebeu configuração própria e passou a ser implantado no Kubernetes. O ambiente acadêmico de validação utiliza Amazon EKS, imagens privadas no Amazon ECR e serviços gerenciados da AWS para persistência, cache e mensageria.

O trabalho contemplou três níveis complementares de execução:

- ambiente local completo com Docker Compose;
- cluster Kubernetes local com Kind para validação dos manifestos;
- implantação real no AWS Academy, com EKS e serviços gerenciados.

O relatório operacional de 29/10/2026 registrou uma validação ponta a ponta: uma requisição externa atravessou o Network Load Balancer e o Nginx Ingress, chegou aos microsserviços, consultou regras e flags, utilizou Redis, publicou um evento no SQS e terminou com a persistência do dado analítico no DynamoDB. As capturas brutas desse ambiente ainda precisam ser anexadas conforme a seção 15.

Essa execução registrada descreve o fluxo funcional da aplicação. Ela não constitui demonstração de scale-out ou scale-in dos HPAs, que exige coleta específica antes, durante e depois de um teste de carga.

2. Objetivo

O objetivo desta fase foi transformar o MVP monolítico do ToggleMaster em um ecossistema distribuído e operável em Kubernetes, atendendo aos seguintes pontos:

- criar imagens Docker otimizadas para os cinco microsserviços;
- executar todo o ecossistema localmente em um único Docker Compose;
- provisionar e utilizar recursos gerenciados na AWS;
- publicar as imagens em cinco repositórios privados do ECR;
- implantar os serviços em um cluster EKS;
- utilizar Namespaces, Deployments, Services, ConfigMaps, Secrets, Ingress e probes;
- disponibilizar acesso externo através de Nginx Ingress e Network Load Balancer;
- implementar escalabilidade horizontal para evaluation e analytics;
- proteger configurações sensíveis com AWS Secrets Manager e External Secrets Operator;
- comprovar o fluxo funcional até a gravação no DynamoDB.

3. Evolução da arquitetura

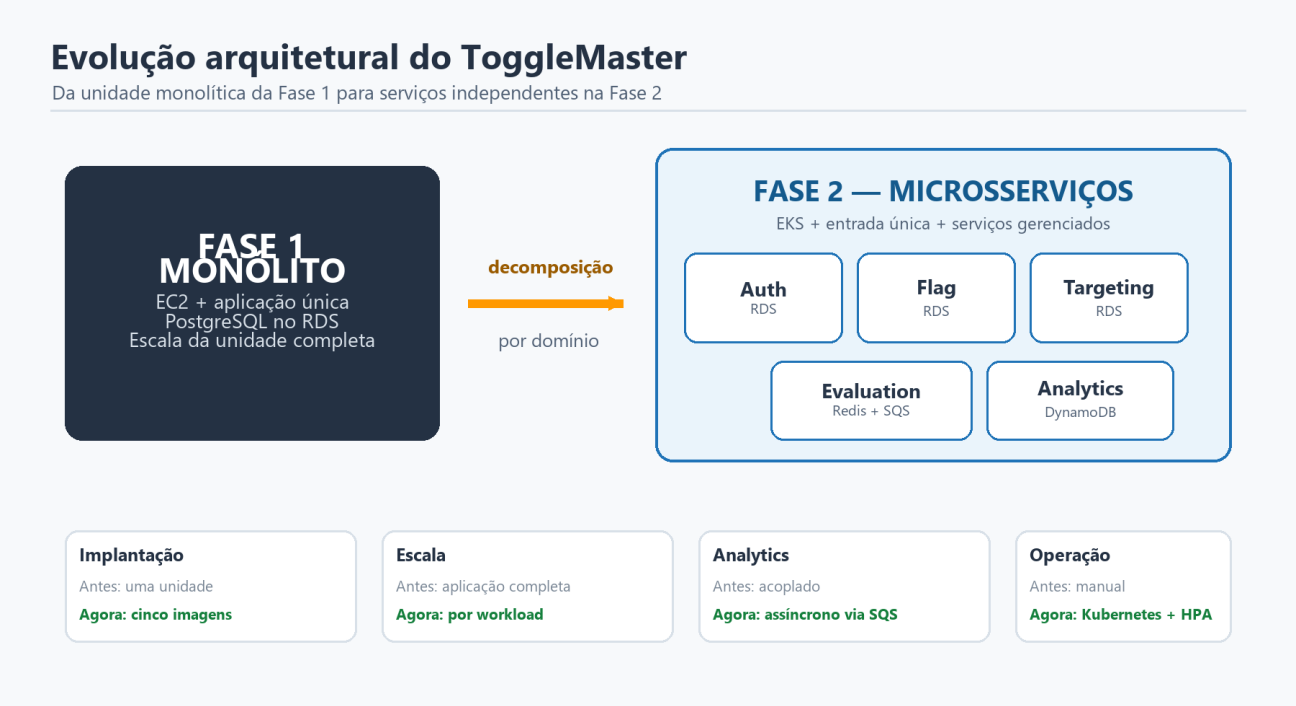


Figura 1 — Evolução arquitetural entre as Fases 1 e 2.

Na arquitetura monolítica, uma única unidade de implantação concentrava autenticação, feature flags, regras, avaliação e persistência. Na nova arquitetura, cada domínio possui um serviço independente, com interface e dependências próprias.

Essa separação permite que o caminho de avaliação, mais sensível à latência, escale sem exigir réplicas adicionais de todas as demais funcionalidades. Também possibilita que o processamento analítico aconteça de forma assíncrona, sem aumentar o tempo de resposta percebido pelo cliente.

3.1 Microsserviços

Serviço	Tecnologia	Porta	Responsabilidade	Dependência principal
auth-service	Go, build 1.22	8001	criação e validação de chaves de API	RDS PostgreSQL Auth
flag-service	Python 3.11	8002	CRUD das definições de feature flags	RDS PostgreSQL Flag
targeting-service	Python 3.11	8003	manutenção de regras de segmentação	RDS PostgreSQL Targeting
evaluation-service	Go, build 1.22	8004	decisão final de avaliação, cache e publicação de eventos	ElastiCache Redis e SQS
analytics-service	Python 3.11	8005	consumo assíncrono e persistência analítica	SQS e DynamoDB

3.2 Fluxo funcional

O cliente cria ou utiliza uma chave no auth-service. As definições das flags ficam sob responsabilidade do flag-service e as regras são mantidas pelo targeting-service. Ao receber uma avaliação, o evaluation-service consulta os dois serviços,

utiliza Redis para reduzir a latência do caminho quente e retorna o resultado booleano. Em seguida, publica um evento no SQS. O analytics-service consome esse evento e grava o registro na tabela DynamoDB.

4. Atendimento aos requisitos da Fase 2

Requisito	Implementação	Situação
Cinco Dockerfiles	Um Dockerfile multi-stage por microsserviço	**Atendido**
Nove containers locais	Cinco aplicações, dois PostgreSQL, um Redis e um LocalStack	**Atendido por equivalência funcional**
DynamoDB local	DynamoDB emulado pelo LocalStack, junto com SQS	**Atendido por equivalência funcional**
Cluster Kubernetes	Kind no ambiente local e EKS ekstogglemaster no AWS Academy (evidência 02)	**Atendido**
Cinco repositórios ECR	Um repositório privado por serviço (evidência 03)	**Atendido**
Três bancos RDS	Auth, Flag e Targeting em instâncias independentes (evidência 04)	**Atendido**
ElastiCache Redis	Redis Cluster com TLS para o evaluation-service (evidência 05)	**Atendido**
DynamoDB	Tabela ToggleMasterAnalytics (evidência 07)	**Atendido**
SQS Standard	Fila tgmqueue (evidência 06)	**Atendido**
Metrics Server	Instalado para fornecer métricas aos HPAs	**Atendido**
Nginx Ingress	ingress-nginx publicado por Classic Load Balancer (evidência 11)	**Atendido**
Namespaces separados	auth, flag, targeting, evaluation e analytics	**Atendido**
Requests, limits e probes	Definidos nos cinco Deployments	**Atendido**
HPA do evaluation	CPU, mínimo 1 e máximo 5 réplicas; escalou sob carga e voltou ao mínimo (evidência 13)	**Atendido**
HPA do analytics	CPU, mínimo 1 e máximo 5 réplicas; escalou de 1 para 5 e voltou ao mínimo (evidência 14)	**Atendido**
Teste ponta a ponta	Validado do Load Balancer até SQS, Analytics e DynamoDB (evidências 07 e 14 e vídeo)	**Atendido**

Os itens de AWS foram comprovados no LAB 2 (conta 533267349027, região us-east-1). As evidências 02 a 13 estão em docs/evidencias_aws_2026-10-30 e a evidência 14, em docs/evidencias_aws_2026-11-02. As seções seguintes mantêm o registro do LAB 1, de 29/10/2026, com outros nomes de recursos.

No LAB 2, o Service do ingress-nginx criou um Classic Load Balancer, enquanto o enunciado menciona ALB ou NLB. O roteamento e a chamada pelo Load Balancer foram comprovados; a diferença de produto permanece declarada.

O enunciado menciona literalmente DynamoDB Local. Foi utilizado LocalStack porque ele oferece equivalência funcional para as APIs de DynamoDB e SQS em um único container, mantendo o total de nove containers e permitindo testar localmente o mesmo fluxo assíncrono usado na AWS.

O LocalStack não é a imagem oficial do DynamoDB Local. Embora o comportamento funcional necessário tenha sido reproduzido, existe risco de o avaliador interpretar a escolha como divergência formal. A documentação apresenta essa decisão como equivalência funcional, e não como aderência literal.

5. Ambiente local com Docker Compose

O arquivo `docker-compose.yml` sobe todos os componentes necessários sem depender de uma conta AWS. Os serviços de aplicação continuam ouvindo internamente nas portas 8001 a 8005; no Windows, são publicadas as portas 18001 a 18005 para evitar conflito com outros projetos.

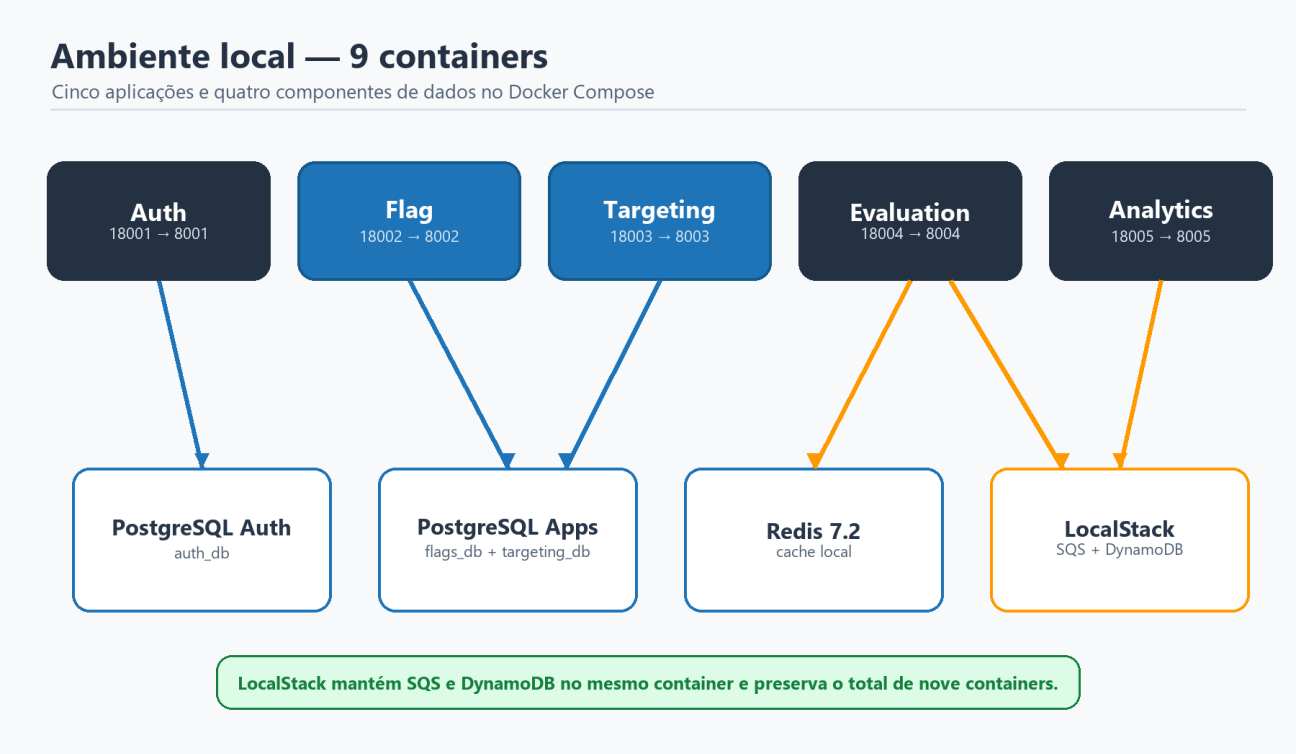


Figura 2 — Ambiente local com cinco aplicações e quatro componentes de dados.

5.1 Containers locais

Container	Imagem ou build	Porta publicada	Finalidade
auth-service	build local	18001	autenticação e chaves de API
flag-service	build local	18002	feature flags
targeting-service	build local	18003	regras de segmentação
evaluation-service	build local	18004	avaliação e publicação de eventos
analytics-service	build local	18005	worker e health endpoint
auth-db	postgres:16-alpine	interna	banco auth_db
apps-db	postgres:16-alpine	interna	bancos flags_db e targeting_db
redis	redis:7.2-alpine	interna	cache de avaliação
aws-local	localstack/localstack:3.8.1	4566	equivalência funcional para SQS e DynamoDB locais

Os health checks e as condições de dependência evitam que as aplicações iniciem antes dos bancos e dos serviços emulados. Os volumes nomeados preservam os dados entre reinicializações.

5.2 Execução local

```
Copy-Item .env.example .env
.\scripts\start-local.ps1
.\scripts\test-local.ps1
docker compose ps
```

O teste automatizado cria uma chave de API, registra uma flag, cria uma regra com 100% de ativação, avalia a flag, aguarda o processamento da fila e confirma a persistência no DynamoDB local.

A execução real e datada de docker compose ps, com os nove containers saudáveis, está registrada na seção 15.

5.3 Kubernetes local

O projeto também inclui um cluster Kind isolado, com Nginx Ingress e Metrics Server. O Ingress local é publicado em `http://localhost:18080`, usando o cabeçalho `Host: togglemaster.local`.

```
.\scripts\setup-kind.ps1
.\scripts\test-k8s.ps1
kubectl get pods -n togglemaster
kubectl get hpa -n togglemaster
```

O Kind não substitui as evidências da AWS, mas reduz o risco de falhas de manifesto antes da aplicação no EKS.

No ambiente Kubernetes local, o HPA do evaluation trabalha entre 2 e 8 réplicas e o do analytics entre 1 e 6, ambos com alvo de CPU de 70%. Esses parâmetros são diferentes do ambiente AWS, onde a faixa é de 1 a 5 réplicas e o alvo foi reduzido para 30% para facilitar a demonstração acadêmica.

6. Conteinerização

Os cinco Dockerfiles utilizam múltiplos estágios. O estágio de build contém compiladores e dependências; o estágio final recebe somente o necessário para execução.

Serviço	Imagem de build	Imagem final	Processo de execução
auth-service	golang:1.22-alpine	alpine:3.20	binário Go estático
flag-service	python:3.11-slim	python:3.11-slim	Gunicorn, 2 workers e 2 threads
targeting-service	python:3.11-slim	python:3.11-slim	Gunicorn, 2 workers e 2 threads
evaluation-service	golang:1.22-alpine	alpine:3.20	binário Go estático
analytics-service	python:3.11-slim	python:3.11-slim	Gunicorn, 1 worker e 2 threads

Boas práticas aplicadas:

- execução como usuário não privilegiado de UID 10001;
- dependências instaladas em estágio separado;
- imagens finais menores, sem compiladores;
- health checks em todos os containers;
- logs direcionados para saída padrão;
- binários Go compilados sem CGO, com símbolos removidos;
- ausência de credenciais reais nas imagens.

7. Arquitetura AWS implantada

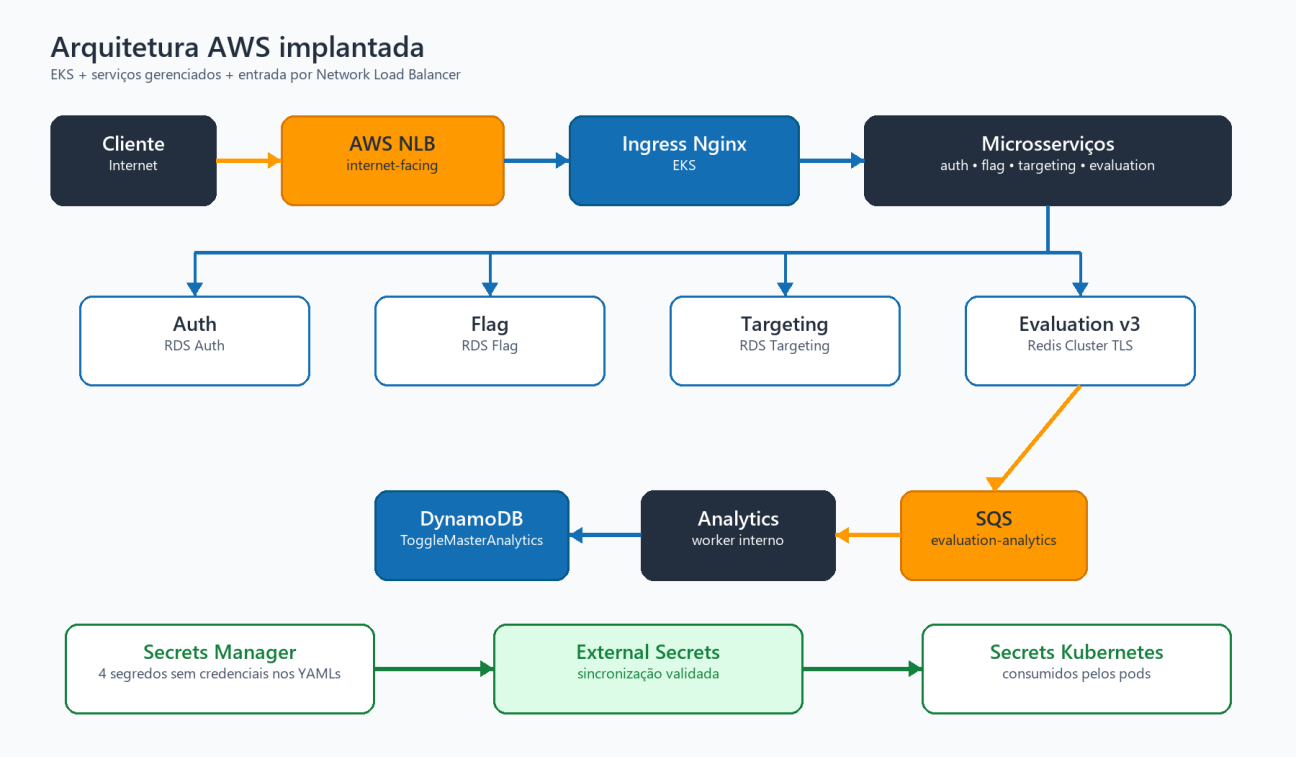


Figura 3 — Arquitetura implantada segundo o registro operacional do AWS Academy de 29/10/2026.

O ambiente foi implantado na conta acadêmica, região `us-east-1`. A entrada pública é fornecida por um Network Load Balancer internet-facing. O tráfego segue para o Nginx Ingress Controller e é encaminhado ao Service Kubernetes correto conforme a rota.

7.1 Inventário principal

Camada	Recurso implantado
Orquestração	EKS `eks-togglemaster`, Kubernetes 1.37
Nós	2 nós em estado Ready
Registro de imagens	cinco repositórios privados no ECR
Entrada	NLB + ingress-nginx chart 4.15.1 / app 1.15.1
Bancos relacionais	três instâncias privadas RDS PostgreSQL
Cache	ElastiCache Redis Cluster com TLS
Mensageria	SQS Standard `evaluation-analytics-queue`
NoSQL	DynamoDB `ToggleMasterAnalytics`
Segredos	AWS Secrets Manager + External Secrets Operator 2.14.0
Escala	Metrics Server + dois HPAs

7.2 Provisionamento do Amazon EKS

O cluster eks-togglemaster foi criado manualmente pelo Console AWS, conforme a alternativa permitida para o AWS Academy. O guia utilizado durante o provisionamento registra a configuração abaixo.

Parâmetro	Valor registrado
Método de criação	Console AWS
Cluster IAM Role	LabRole
Node IAM Role	LabRole
Managed Node Group	tgmnodegroup no LAB 2 (evidência 02); eks-nodegroup-academy-v2 no LAB 1
AMI	Amazon Linux 2023 (AL2023) x86_64
Tipo das instâncias	t3.medium
Armazenamento por nó	20 GB gp3
Capacidade mínima	1 nó
Capacidade desejada	2 nós
Capacidade máxima	4 nós

No LAB 2, a evidência 02 confirma o Managed Node Group tgmnodegroup, com instâncias t3.medium ON_DEMAND e escala 1/2/4. No LAB 1, o grupo equivalente era o eks-nodegroup-academy-v2, registrado no apêndice Validação final do AWS Lab.

7.3 Imagens publicadas

Serviço	URI do repositório ECR	Versão registrada
auth-service	058264096738.dkr.ecr.us-east-1.amazonaws.com/ecr/auth-service	v1
flag-service	058264096738.dkr.ecr.us-east-1.amazonaws.com/ecr/flag-service	v1
targeting-service	058264096738.dkr.ecr.us-east-1.amazonaws.com/ecr/targeting-service	v1
evaluation-service	058264096738.dkr.ecr.us-east-1.amazonaws.com/ecr/evaluation-service	v3
analytics-service	058264096738.dkr.ecr.us-east-1.amazonaws.com/ecr/analytics-service	v1

A versão `v3` do evaluation-service contém a correção de compatibilidade com o Redis 7 do ElastiCache. O digest registrado no ECR foi `sha256:8e6fdb41e384e0f929a39d1cc5ac5234f76d6997fd249ec05092c70bbf6d6c0d`.

7.4 Endpoint externo

```
http://ae6a5981f8069438481a714114fef81d-9676d8a498457cbb.elb.us-east-1.amazonaws.com
```

Esse DNS é gerado pela AWS e pode mudar se o Service do ingress-nginx for recriado. A raiz `/` não possui rota e, portanto, retorna `404 Not Found` do Nginx. Esse retorno não indica falha do Load Balancer; as rotas válidas são as definidas nos Ingresses.

Na tentativa de revalidação realizada em 29/10/2026 às 01:35 BRT, o endereço histórico não respondeu na porta 80. Ele permanece documentado como endpoint observado no snapshot da implantação, e não como endpoint atualmente disponível. No LAB 2, o Service do ingress-nginx criou o Classic Load Balancer a5bc56a01f92c4e85887af601f04b84e-1447597342.us-east-1.elb.amazonaws.com, com os dois nós InService e as rotas validadas (evidência 11 e vídeo).

8. Kubernetes no EKS

Cada domínio possui seu próprio Namespace. Essa separação simplifica a organização, limita colisões de nomes e prepara o ambiente para políticas mais específicas.

Namespace	Deployment	Service	Porta
auth	auth-service	ClusterIP	8001
flag	flag-service	ClusterIP	8002
targeting	targeting-service	ClusterIP	8003
evaluation	evaluation-service	ClusterIP	8004
analytics	analytics-service	ClusterIP	8005

8.1 Recursos e probes

Serviço	CPU request/limit	Memória request/limit	Probes
auth	100m / 500m	128Mi / 256Mi	startup, readiness e liveness HTTP
flag	100m / 500m	128Mi / 384Mi	startup, readiness e liveness HTTP
targeting	100m / 500m	128Mi / 384Mi	startup, readiness e liveness HTTP
evaluation	100m / 500m	128Mi / 256Mi	startup, readiness e liveness HTTP
analytics	100m / 500m	128Mi / 384Mi	startup TCP, readiness HTTP e liveness TCP

Os requests permitem ao scheduler reservar capacidade, enquanto os limits reduzem o risco de consumo excessivo. Em auth, flag, targeting e evaluation, as probes HTTP confirmam que o processo web responde, mas não validam todas as dependências externas, como PostgreSQL, Redis, SQS ou chamadas entre serviços. No analytics, a readiness HTTP consulta o estado do worker, enquanto as probes TCP verificam somente a abertura da porta. As probes melhoram a recuperação do processo, mas não comprovam sozinhas a saúde completa das integrações.

8.2 Roteamento do Ingress

Operação	Método e rota pública	Destino interno
Saúde do Auth	GET `/auth/health`	auth-service:8001 `/health`
Criar API key	POST `/auth/admin/keys`	auth-service:8001 `/admin/keys`
Validar API key	GET `/auth/validate`	auth-service:8001 `/validate`
Feature flags	GET/POST `/flags`	flag-service:8002
Flag específica	GET/PUT/DELETE `/flags/{name}`	flag-service:8002
Regras	POST `/rules`	targeting-service:8003
Regra específica	GET/PUT/DELETE `/rules/{flag_name}`	targeting-service:8003
Avaliação	GET `/evaluate?user_id={id}&flag_name={flag}`	evaluation-service:8004

O analytics-service é um worker interno e não possui Ingress público.

8.3 Inicialização dos bancos

Três Jobs Kubernetes executam os scripts SQL de inicialização:

- `auth-db-init`;
- `flag-db-init`;
- `targeting-db-init`.

Durante a validação, os três Jobs atingiram o estado `Succeeded`. Como possuem limpeza automática após a conclusão, eles podem não permanecer listados indefinidamente. Os scripts ficam em ConfigMaps e as URLs de conexão são obtidas dos Secrets sincronizados.

9. Serviços de dados e mensageria

Os recursos foram escolhidos de acordo com o perfil de cada dado, evitando utilizar um único banco para todas as necessidades.

Serviço AWS	Tipo de dado	Motivo da escolha
RDS PostgreSQL	chaves, flags e regras	consistência transacional, relacionamentos e consultas estruturadas
ElastiCache Redis	resultados temporários de avaliação	baixa latência e acesso rápido no caminho quente
DynamoDB	eventos analíticos	alta escala, persistência NoSQL e acesso por chave
SQS	eventos de avaliação	desacoplamento, absorção de picos e processamento assíncrono

9.1 RDS PostgreSQL

Auth, Flag e Targeting utilizam instâncias independentes. Essa abordagem evita que um serviço acesse diretamente as tabelas de outro e preserva a autonomia dos domínios. As instâncias não são publicamente acessíveis; a porta 5432 é liberada somente para a origem autorizada do EKS.

9.2 ElastiCache Redis

O evaluation-service utiliza Redis Cluster com criptografia em trânsito. A conexão usa TLS e autenticação, armazenadas fora dos manifestos. O cache reduz chamadas repetidas aos serviços de flag e targeting durante a janela configurada.

9.3 SQS e DynamoDB

Depois de responder ao cliente, o evaluation-service publica um evento na fila. O analytics-service realiza long polling, grava o item no DynamoDB e somente então remove a mensagem da fila. Assim, a persistência analítica não bloqueia o caminho síncrono da avaliação.

O SQS Standard oferece entrega pelo menos uma vez. O ensaio confirmou o fluxo ponta a ponta, mas a implementação ainda não apresenta DLQ, idempotência baseada no identificador da mensagem ou padrão outbox. Se a gravação ocorrer e a remoção da mensagem falhar, uma nova tentativa pode gerar duplicidade. Além disso, a publicação pelo evaluation ocorre de forma assíncrona e ainda não possui retry persistente. Essas garantias adicionais ficam como evolução para produção.

9.3.1 Esquema da tabela analítica

Propriedade	Valor
Tabela	ToggleMasterAnalytics
Partition key	event_id
Tipo da chave	String (S)

Cada evento recebe um event_id antes da operação PutItem. Os demais atributos são armazenados de forma flexível, conforme o conteúdo do evento analítico.

10. Segurança

A implantação evita armazenar credenciais temporárias ou senhas diretamente nos YAMLs.

10.1 Gestão de segredos

```
AWS                                                Secrets                                                Manager
        ↓
ClusterSecretStore
        ↓
External                                             Secrets                                              Operator
        ↓
Secrets                                                                                                  Kubernetes
        ↓
Pods autorizados
```

Foram utilizados quatro documentos no Secrets Manager: `togglemaster/auth`, `togglemaster/flag`, `togglemaster/targeting` e `togglemaster/evaluation`. As três URLs de banco, a chave administrativa, o token Redis e a chave interna do evaluation permanecem no serviço gerenciado.

No LAB 2, a coleta de 30/10/2026 registrou o ClusterSecretStore aws-secrets-manager em estado Valid e quatro recursos ExternalSecret com SecretSynced=True (evidência 10, seção 15).

Cada recurso ExternalSecret faz o External Secrets Operator criar ou atualizar um Secret nativo do Kubernetes. Nesse objeto, os valores ficam no campo data, codificados em Base64. Base64 é codificação reversível, não criptografia. A confidencialidade depende dos controles do AWS Secrets Manager, do RBAC e da proteção dos Secrets no cluster; nenhuma evidência deve exibir ou decodificar esses valores.

O intervalo de sincronização é de um minuto. Como os serviços consomem esses valores por variáveis de ambiente, uma rotação atualiza o Secret Kubernetes, mas os pods em execução precisam de rollout controlado ou de um reloader para receber o novo valor.

10.2 Segurança dos containers

Nos Deployments foram aplicados:

- `runAsNonRoot: true`;
- usuário e grupo 10001;
- `allowPrivilegeEscalation: false`;
- filesystem raiz somente leitura;
- remoção de todas as Linux capabilities;
- perfil seccomp `RuntimeDefault`;
- volumes temporários `emptyDir` somente quando necessários.

10.3 Rede e identidade

RDS e ElastiCache permanecem privados. Os Security Groups liberam somente EKS para RDS em TCP 5432 e EKS para Redis em TCP 6379. O NLB expõe o Ingress, não os bancos.

No AWS Academy, a LabRole existente foi utilizada porque o laboratório não permite criar roles específicas. O IMDSv2 foi mantido obrigatório e o hop limit foi configurado como 2 para permitir que os pods alcançassem as credenciais temporárias do nó. Essa é uma limitação do laboratório; em produção, a recomendação é usar EKS Pod Identity ou IRSA com políticas mínimas por serviço.

Limite do laboratório: o endpoint observado utiliza HTTP. Chaves enviadas à API, inclusive a Master Key usada na rota administrativa, não devem trafegar dessa forma em produção. Também não há NetworkPolicy, WAF ou rate limiting comprovados. Namespaces organizam os recursos, mas não isolam o tráfego por si só. Uma publicação real exige HTTPS, restrição da rota administrativa, controles de borda e segmentação de rede.

11. Escalabilidade e resiliência

O Metrics Server fornece utilização de CPU aos HPAs. Foram criados dois recursos `autoscaling/v2`:

HPA	Mínimo	Máximo	Métrica	Alvo	Estabilização de scale-down
evaluation-service-hpa	1	5	CPU média	30%	60 segundos
analytics-service-hpa	1	5	CPU média	30%	60 segundos

O alvo de 30% foi adotado para tornar uma futura demonstração mais sensível no ambiente acadêmico. O evaluation foi configurado para aumentar réplicas quando a carga HTTP elevar a CPU; o analytics foi configurado para reagir quando o consumo de mensagens elevar sua utilização de CPU.

Os dois HPAs recebem métricas do Metrics Server e estão configurados nos manifests. Até esta versão do documento, porém, não foi registrada uma sequência antes, durante e depois da carga que comprove o scale-out e o retorno ao mínimo. Esta seção descreve capacidade configurada, não escalabilidade demonstrada.

O KEDA seria mais apropriado para escalar o analytics diretamente pela profundidade da fila, inclusive de zero réplicas. Ele não foi usado porque a criação das roles necessárias não é permitida pela LabRole do AWS Academy. O HPA por CPU é o workaround previsto no enunciado.

Além da configuração de escala horizontal, a solução utiliza readiness e liveness probes, reinício automático dos containers, fila para amortecer picos e dois nós observados como Ready no snapshot de 29/10/2026.

O registro histórico de dois targets saudáveis do NLB e dois nós não significa alta disponibilidade completa das aplicações. A réplica inicial dos Deployments é 1, e não foram configurados PodDisruptionBudgets, anti-affinity ou topology spread. O HPA oferece capacidade de escala, mas a distribuição e a tolerância a interrupções ainda podem evoluir.

12. Configuração e sequência de implantação

A implantação foi executada em uma ordem que reduz dependências circulares e facilita o diagnóstico.

1. Validar conta, região, recursos gerenciados e repositórios ECR.
2. Publicar as cinco imagens nos respectivos repositórios.
3. Validar o EKS e recuperar os dois nós.
4. Ajustar o hop limit do IMDS para 2, mantendo IMDSv2 obrigatório.
5. Liberar os fluxos de rede EKS para RDS e ElastiCache.
6. Instalar Metrics Server, ingress-nginx e External Secrets Operator.
7. Criar o ClusterSecretStore e sincronizar os quatro segredos.
8. Executar os três Jobs de inicialização SQL.
9. Aplicar Deployments, Services, ConfigMaps, Ingresses e HPAs.
10. Validar pods, probes, endpoints e logs.
11. Publicar a correção do evaluation-service como v3 e executar o rollout.
12. Provisionar o NLB através do Service do ingress-nginx.
13. Executar o smoke test externo completo.

Comandos operacionais principais:

```
kubectl                                    kustomize                                    .\k8s-aws
kubectl                              apply                              -k             .\k8s-aws
kubectl                            get                            pods,svc,ingress,hpa        -A
kubectl                              get                                externalsecret      -A
kubectl get clustersecretstore
```

13. Correção do evaluation-service

Durante o rollout inicial, o evaluation-service encerrava ao interpretar a resposta `CLUSTER SLOTS` do Redis 7 do ElastiCache. A biblioteca `github.com/go-redis/redis/v8 v8.11.5` aceitava somente duas ou três posições no endereço do nó, mas o serviço gerenciado retornava quatro.

Erro observado:

```
got 4 elements in cluster info address, expected 2 or 3
```

A solução aplicada foi:

- migrar para `github.com/redis/go-redis/v9 v9.18.0`;
- preservar TLS 1.2, autenticação e cluster mode;
- atualizar os testes do serviço;
- executar os testes com Go 1.22;
- gerar e publicar a imagem `evaluation-service:v3`;
- atualizar manifesto EKS, Compose AWS e documentação;
- executar novo rollout no cluster.

Após a correção, os logs confirmaram conexão com o Redis Cluster e inicialização do cliente SQS. Esse incidente demonstrou a importância de validar bibliotecas contra a resposta real do serviço gerenciado, não apenas contra o Redis local standalone.

14. Validação da aplicação



Figura 4 — Sequência registrada no relatório operacional do smoke test externo.

Segundo o relatório operacional de 29/10/2026, o teste realizado pelo endpoint do NLB executou as etapas abaixo. No LAB 2, o mesmo fluxo foi repetido pelo Load Balancer e aparece no vídeo (12:03); os eventos gravados estão nas evidências 07 e 14:

14. criação de uma API key com a chave administrativa;
15. validação da nova API key no auth-service;
16. criação de uma feature flag habilitada;
17. criação de uma regra do tipo `PERCENTAGE` com valor 100;
18. chamada externa ao endpoint `/evaluate`;
19. retorno booleano `true`;
20. publicação do evento no SQS;
21. consumo da mensagem pelo analytics-service;
22. gravação na tabela `ToggleMasterAnalytics`;
23. remoção da flag e da regra temporárias.

Esse registro de smoke test descreve o fluxo funcional até o DynamoDB, mas não substitui a evidência bruta, não foi um teste de carga e não comprova scale-out dos HPAs.

Resposta funcional observada:

```
{
  "flag_name": "<flag-de-teste>",
  "user_id": "<usuario-de-teste>",
  "result": true
}
```

14.1 Teste seguro pelo endpoint público

```
$base = 'http://ae6a5981f8069438481a714114fef81d-9676d8a498457cbb.elb.us-east-1.amazonaws.com'
Invoke-RestMethod "$base/auth/health"
Invoke-RestMethod "$base/auth/validate" -Headers @{ Authorization = 'Bearer <API_KEY>' }
Invoke-RestMethod "$base/evaluate?user_id=usuario&flag_name=nome-da-flag"
```

As chaves devem ser informadas em tempo de execução e nunca incluídas em scripts versionados ou documentos.

15. Evidências reais e rastreabilidade

Item verificado	Evidência do LAB 2 (30/10 e 02/11/2026)	Resultado
EKS	cluster `ekstogglemaster`, Kubernetes 1.37, ACTIVE	**Atendido — evidência 02**
Nós	dois nós t3.medium Ready no `tgmnodegroup` (1/2/4)	**Atendido — evidência 02**
Aplicações	cinco Deployments disponíveis em 1/1	**Atendido — evidência 09**
Estabilidade	pods em Running, sem reinicializações	**Atendido — evidência 09**
Inicialização SQL	três Jobs SQL concluídos e removidos depois pelo TTL	**Atendido — EVIDENCIAS_AWS_LAB_2026-10-30.md**
Segredos	quatro ExternalSecrets com `SecretSynced=True`	**Atendido — evidência 10**
Secret store	ClusterSecretStore `aws-secrets-manager` Valid	**Atendido — evidência 10**
Load Balancer	Classic Load Balancer internet-facing criado pelo ingress-nginx	**Atendido — evidência 11 (Classic, não ALB/NLB)**
Targets	dois nós InService nas portas 80 e 443	**Atendido — evidência 11**
Escalabilidade	evaluation e analytics foram de 1 para 5 réplicas e voltaram a 1	**Atendido — evidências 13 e 14**
Avaliação	chamada pelo Load Balancer com `EvaluationResult = True`	**Atendido — vídeo, 12:03**
Mensageria	6000 mensagens enviadas manualmente e consumidas na `tgmqueue`	**Atendido — evidência 14**
Analytics	eventos no DynamoDB: 4 de `load-postman-fiap` e 6000 do lote enviado	**Atendido — evidências 07 e 14**

15.1 Docker Compose — coleta atual

Comando docker compose ps executado em 29/10/2026 às 01:33:46 BRT. Os nove containers estavam em execução e saudáveis.

Serviço	Imagem	Estado	Porta
analytics-service	togglemaster/analytics-service:local	Up — healthy	18005 → 8005
apps-db	postgres:16-alpine	Up — healthy	interna
auth-db	postgres:16-alpine	Up — healthy	interna
auth-service	togglemaster/auth-service:local	Up — healthy	18001 → 8001
aws-local	localstack/localstack:3.8.1	Up — healthy	4566
evaluation-service	togglemaster/evaluation-service:local	Up — healthy	18004 → 8004
flag-service	togglemaster/flag-service:local	Up — healthy	18002 → 8002
redis	redis:7.2-alpine	Up — healthy	interna
targeting-service	togglemaster/targeting-service:local	Up — healthy	18003 → 8003

Na mesma coleta, scripts/test-local.ps1 validou os cinco health endpoints, autenticação, criação de flag e regra, avaliação true e persistência no DynamoDB emulado; a contagem de itens passou de 4 para 5.

15.2 Kubernetes local — baseline dos HPAs

Snapshot de 29/10/2026 às 01:36:29 BRT, sem geração de carga:

HPA local	CPU / alvo	Mínimo	Máximo	Réplicas
analytics-service	7% / 70%	1	6	1
evaluation-service	1% / 70%	2	8	2

O snapshot comprova que os HPAs locais recebem métricas, mas representa somente o estado inicial; não demonstra scale-out nem scale-in.

15.3 Inventário AWS comprovado no LAB 2

O inventário abaixo vem das coletas do LAB 2 (conta 533267349027, região us-east-1), feitas com AWS CLI e kubectl em 30/10/2026 e, no caso do analytics, em 02/11/2026. As evidências estão em docs/evidencias_aws_2026-10-30 e docs/evidencias_aws_2026-11-02. O registro anterior, do LAB 1, de 29/10/2026, usava outra conta e outros nomes de recursos.

Item exigido	Recurso no LAB 2	Situação
Cinco ECR	`533267349027.dkr.ecr.us-east-1.amazonaws.com/namespace/`: auth-service:v1, lag-service:v1 (flag), targeting-service:v1, evaluation-service:v3 e analytics-service:v1	**Atendido — evidência 03**
EKS e Node Group	`ekstogglemaster`, Kubernetes 1.37; `tgmnodegroup` t3.medium, 1/2/4, dois nós Ready	**Atendido — evidência 02**
Cinco aplicações	auth, flag, targeting, evaluation e analytics em 1/1	**Atendido — evidência 09**
Três RDS	`db-authservice`, `dbflags` e `dbtargeting`, privados e criptografados	**Atendido — evidência 04**
ElastiCache	`redisevaluation`, cluster mode, TLS, AUTH e criptografia em repouso	**Atendido — evidência 05**
SQS	`tgmqueue` Standard, com criptografia gerenciada pela AWS	**Atendido — evidência 06**
DynamoDB	`ToggleMasterAnalytics`, PAY_PER_REQUEST, chave `event_id`	**Atendido — evidências 07 e 14**
ExternalSecrets	4 recursos `SecretSynced=True`; store `Valid`	**Atendido — evidência 10**
Load Balancer e Ingress	Classic Load Balancer internet-facing e 4 rotas Ingress	**Atendido — evidências 09 e 11; Classic difere de ALB/NLB**
HPAs	autoscaling/v2, CPU 30%, mínimo 1, máximo 5	**Atendido — evidências 13 e 14**

15.4 Demonstração dos HPAs no EKS

Momento	Registro observado	Estado
Antes da carga	evaluation 1/1 com CPU 1%/30% (31/10); analytics com 1 réplica e CPU 2%/30% (02/11)	**Atendido**
Durante a carga	evaluation: CPU 59% e depois 172%, até 5 réplicas; analytics: CPU 340%/30% com 6000 mensagens no SQS, de 1 para 5 réplicas	**Atendido**
Depois da carga	os dois voltaram a 1 réplica, com CPU 1%/30%	**Atendido**

As duas sequências foram registradas no EKS: evaluation em 31/10/2026 (evidência 13) e analytics em 02/11/2026 (evidência 14). Os dois trechos também aparecem no vídeo, a partir de 12:21 e de 13:28.

16. Arquitetura de microsserviços

16.1 Vantagens

- escalabilidade independente do caminho de avaliação e do worker analítico;
- isolamento de falhas e responsabilidades;
- deploy separado por serviço;
- possibilidade de escolher a tecnologia adequada a cada domínio;
- bancos e recursos de dados alinhados ao tipo de carga;
- processamento assíncrono para reduzir o acoplamento temporal;
- evolução gradual de cada componente.

16.2 Desvantagens e novos custos operacionais

- mais componentes para implantar, observar e proteger;
- necessidade de descoberta de serviços e roteamento;
- maior complexidade de diagnóstico entre chamadas distribuídas;
- consistência eventual no processamento analítico;
- gestão de versões de imagens e contratos de API;
- custo de cluster, Load Balancer e serviços gerenciados;
- necessidade futura de tracing, métricas e logs centralizados.

17. Análise dos 12-Factor App

Fator	Situação na Fase 2	Análise
I. Codebase	Atende	código organizado por serviço e manifestos versionáveis
II. Dependencies	Atende	Go Modules e requirements.txt; builds reproduzíveis em containers
III. Config	Atende	ConfigMaps e Secrets externos ao código
IV. Backing Services	Atende	RDS, Redis, SQS e DynamoDB tratados como recursos substituíveis
V. Build, Release, Run	Atende parcialmente	estágios separados, porém ainda sem pipeline CI/CD completo
VI. Processes	Atende	aplicações stateless; estado mantido em serviços externos
VII. Port Binding	Atende	cada serviço publica sua própria porta HTTP
VIII. Concurrency	Atende parcialmente	Deployments e HPAs permitem múltiplas réplicas, mas o comportamento sob carga ainda precisa de evidência
IX. Disposability	Atende parcialmente	probes e reinício automático; graceful shutdown pode evoluir
X. Dev/Prod Parity	Atende parcialmente	mesmas APIs; LocalStack oferece equivalência funcional, não aderência literal ao DynamoDB Local
XI. Logs	Atende parcialmente	logs em stdout; falta centralização e correlação
XII. Admin Processes	Atende	inicialização de banco executada por Jobs Kubernetes

Em comparação com a Fase 1, houve avanço expressivo em configuração externa, concorrência, processos stateless, separação de backing services e automação operacional.

18. Considerações de custos

O ambiente foi executado no AWS Academy e não foi registrada uma estimativa financeira consolidada para a Fase 2. Por isso, este documento não apresenta valores simulados como se fossem cobrança real.

Os principais direcionadores de custo em uma conta de produção seriam:

- plano de controle do EKS;
- instâncias do Managed Node Group;
- três instâncias RDS e armazenamento;
- ElastiCache Redis Cluster;
- Network Load Balancer e processamento de dados;
- armazenamento e transferência do ECR;
- requisições e armazenamento de SQS e DynamoDB;
- observabilidade no CloudWatch;
- tráfego entre zonas e eventual NAT Gateway.

Uma estimativa formal deve registrar região, tipos de instância, armazenamento, alta disponibilidade, volume de requisições e tráfego. Esses valores devem ser calculados no AWS Pricing Calculator próximo da data da entrega.

19. Desafios encontrados

- adaptação do projeto às limitações de IAM do AWS Academy;
- acesso dos pods aos serviços AWS usando a LabRole do nó;
- ajuste seguro do IMDSv2 e hop limit;
- comunicação privada entre EKS, três RDS e ElastiCache;
- sincronização de segredos sem credenciais estáticas nos YAMLs;
- inicialização independente dos três bancos;
- compatibilidade entre a biblioteca Redis e o Redis 7 em cluster mode;
- migração do Load Balancer clássico para NLB;
- validação de todos os caminhos do Ingress;
- confirmação do fluxo assíncrono até o DynamoDB;
- manutenção de equivalência funcional entre o ambiente local e a AWS.

20. Decisões técnicas

Microsserviços por domínio: autenticação, flags, targeting, avaliação e analytics foram separados para reduzir acoplamento e permitir escala independente.

SQS entre avaliação e analytics: o caminho síncrono retorna rapidamente e o processamento analítico ocorre de forma assíncrona.

Redis no caminho quente: avaliações repetidas podem ser atendidas com menor latência.

Três RDS independentes: cada serviço relacional controla seu próprio esquema e credenciais.

LocalStack no ambiente local: SQS e DynamoDB são reproduzidos por equivalência funcional em um único container, preservando o total de nove containers. Como o enunciado cita literalmente DynamoDB Local, existe risco de interpretação formal pelo avaliador.

Kustomize para os manifestos AWS: permite renderização e aplicação conjunta, mantendo os diretórios organizados por domínio.

External Secrets Operator: evita copiar valores sensíveis para os manifestos e automatiza a sincronização com o Secrets Manager.

HPA por CPU: solução compatível com as limitações do AWS Academy; KEDA foi mantido como evolução recomendada.

NLB com ingress-nginx: oferece um único ponto de entrada e roteamento por caminho para os serviços públicos.

21. Limitações e melhorias recomendadas

24. Publicar o endpoint em um domínio Route 53 e habilitar HTTPS com certificado ACM.
25. Substituir LabRole e acesso via IMDS por EKS Pod Identity ou IRSA.
26. Aplicar políticas IAM mínimas e específicas para evaluation e analytics.
27. Implantar observabilidade centralizada com métricas, logs, alertas e tracing distribuído.
28. Criar pipeline CI/CD para testes, build, scan, publicação no ECR e rollout.
29. Utilizar tags imutáveis ou digest nos Deployments de todos os serviços.
30. Criar PodDisruptionBudgets e políticas de afinidade para maior disponibilidade.
31. Avaliar NetworkPolicies entre os Namespaces.
32. Configurar HTTPS, rate limiting e proteção de borda.
33. Usar KEDA para o analytics em uma conta que permita as roles necessárias.
34. Realizar testes de carga documentados e registrar o comportamento dos HPAs.
35. Automatizar a infraestrutura com Terraform ou outra ferramenta de IaC.
36. Adicionar DLQ, idempotência, alarmes e retry/outbox ao fluxo SQS.
37. Automatizar o rollout após rotação de Secrets.
38. Revisar os pools de conexão e a exposição de detalhes de erro dos serviços Python.

22. Conclusão

A Fase 2 transformou o ToggleMaster de um MVP monolítico em uma plataforma de microsserviços conteinerizada e implantada em Kubernetes. A execução local foi revalidada, e a implantação no EKS foi comprovada no LAB 2, com as evidências 02 a 14 reunidas na seção 15.

O uso combinado de RDS, ElastiCache, SQS e DynamoDB alinhou cada tipo de dado ao serviço mais adequado. O Nginx Ingress e o Load Balancer forneceram uma entrada única, e o Metrics Server com os HPAs garantiu a escala horizontal: o evaluation e o analytics foram de 1 para 5 réplicas sob carga e voltaram ao mínimo. A gestão de segredos foi elevada para o AWS Secrets Manager, sincronizado pelo External Secrets Operator.

O teste ponta a ponta confirmou a integração entre todas as camadas: autenticação, configuração de flags, regras, avaliação, cache, fila e analytics. A correção realizada no cliente Redis também demonstrou capacidade de diagnóstico e adaptação a diferenças reais entre o ambiente local e um serviço gerenciado.

Como próximos passos, a arquitetura deve evoluir em identidade por workload, HTTPS, CI/CD e observabilidade. Mesmo com as restrições do AWS Academy, o ambiente entregue estabelece uma base coerente para operação, escala e melhoria contínua.

23. Links e arquivos da entrega

Item	Informação
Repositório principal	Tech Challenge Fase 2 — ToggleMaster
Vídeo de demonstração	https://youtu.be/lcheHRVKTW8 (YouTube, 18:19)
Diagrama de arquitetura	`docs/arquitetura_aws_togglemaster.png`
Manifestos AWS	`k8s-aws/` e `k8s-aws.zip`
Docker Compose local	`docker-compose.yml`
Docker Compose com AWS	`docker-compose.aws.yml`
Relatório operacional	`docs/Relatorio_Implantacao_AWS_ToggleMaster.docx`
Documento final da Fase 2	`docs/Tech_Challenge_Fase_2_ToggleMaster.docx` e `.pdf`

Checklist antes do envio

- ☑ RM e Discord dos cinco integrantes preenchidos;
- ☑ link definitivo do repositório inserido;
- ☑ link do vídeo da Fase 2 inserido (YouTube, 18:19);
- ☑ Managed Node Group tgmnodegroup, t3.medium e escala 1/2/4 confirmados (evidência 02);
- ☑ evidências AWS datadas anexadas (evidências 02 a 14, seção 15);
- ☑ HPA registrado antes, durante e depois da carga (seção 15.4);
- ☑ rotas validadas pelo Load Balancer do LAB 2 (evidência 11 e vídeo).

- ☑ capturas sem credenciais; IP administrativo mascarado no vídeo e na evidência 08;
- ☑ PDF regenerado após os ajustes deste documento;
- ☑ sumário e paginação atualizados na exportação;

Documento elaborado a partir dos arquivos do projeto, dos manifestos e do registro operacional do estado AWS em 29/10/2026. As evidências do LAB 2, de 30/10 e 02/11/2026, estão reunidas na seção 15. Nenhuma credencial temporária, senha, token ou API key foi incluída.

Validação final do AWS Lab

Snapshot: 2026-10-29 23:04 BRT • Conta 058264096738 • Região us-east-1

Evidência sanitizada: nenhum access key, session token, senha, AUTH token, MASTER_KEY, API key ou valor de Secret foi registrado.

Item	Evidência observada	Status
EKS	eks-togglemaster ACTIVE; Kubernetes 1.37	**CONFIRMADO**
Node Group	eks-nodegroup-academy-v2; LT v2; escala 1/2/4	**CONFIRMADO**
Nós	2 × t3.medium Ready; AL2023; IMDSv2 required; hop 2	**READY**
Aplicações	auth, flag, targeting, evaluation e analytics 1/1	**READY**
Jobs SQL	auth-db-init, flag-db-init e targeting-db-init 1/1	**CONCLUÍDO**
External Secrets	Store Valid; quatro ExternalSecrets SecretSynced	**READY**
NLB / Ingress	NLB ACTIVE; targets healthy; /auth/health HTTP 200	**OPERACIONAL**
Smoke test	Evaluation=true; SQS consumida; evento filtrado confirmado no DynamoDB	**APROVADO**
HPAs	CPU 1%/30% em evaluation e analytics; uma réplica. A escala foi comprovada depois, no LAB 2 (evidências 13 e 14)	**BASELINE**

Identidade de execução do EKS

Item	Evidência observada	Status
Cluster IAM Role	LabRole	**MANTIDA**
Node IAM Role	arn:aws:iam::058264096738:role/c230609a5802546l17969461t1w058264096-LabEksNodeRole-QsDRDcCNRmOV	**PRÉ-CRIADA PELO LAB**
Launch Template	lt-eks-togglemaster-academy / lt-0e7bf115323348621 / versão 2	**ATIVO**
Node Group antigo	eks-nodegroup: min 0, desejado 0, máximo 4	**SEM INSTÂNCIAS**

Fluxo funcional observado

Foi criada uma flag temporária única e uma regra PERCENTAGE=100. A chamada GET /evaluate retornou result=true. O evaluation-service registrou o envio ao SQS; o analytics-service registrou a persistência no DynamoDB; a consulta filtrada passou de 0 para 1. Ao final, a regra e a flag foram removidas. A fila terminou com zero mensagens visíveis e zero em processamento.

Decisões e limitações

- Não foram criadas nem alteradas IAM Roles; foram usadas roles fornecidas pelo AWS Academy.
- O acesso dos pods via IMDS/hop 2 é um workaround acadêmico. Em produção, use Pod Identity ou IRSA e HTTPS.
- Base64 no campo data de Kubernetes Secret é codificação reversível, não criptografia.

- Os HPAs do evaluation e do analytics escalaram sob carga no LAB 2 e voltaram ao mínimo (evidências 13 e 14). O do analytics usa CPU, e não o tamanho da fila; KEDA seria a alternativa por fila.
- ElastiCache possui 3 shards × 3 nós cache.r7g.large. É funcional, porém há alerta de custo e necessidade de right-size.